

# Méthodes de discrimination

## Partie IV – Comparaison de méthodes

2019

Brigitte Gelein – [bgelein@ensai.fr](mailto:bgelein@ensai.fr)

Marine Depecker

B. Gelein  
M. Depecker



B. Gelein  
M. Depecker

# Sommaire

Contexte	4
1. Matrice de confusion	5
2. Courbe ROC	13
3. Aire sous la courbe ROC	37
4. Courbe LIFT	41
5. Aire sous la courbe LIFT	48
6. Conclusion	50

B. Gelein  
M. Depecker



3

## Contexte

- Comparaison des résultats des méthodes de **discrimination (classement)**
  - *Analyse discriminante – (LDA ou QDA)*
  - *Arbre de classement – (Classification trees)*
  - *Bayésien naïf*
  - *Les K plus proches voisins*
- Problématique de **classement**
  - **Variable à expliquer Y nominale (ou ordinale)**
    - « Classes », « étiquettes », « labels », etc.
  - Variables explicatives X de nature diverse

B. Gelein  
M. Depecker



B Gelein - 4

1 - Matrice de confusion

Contexte de la classification binaire

Principe : confronter la vraie valeur avec la prédiction

		Valeurs prédites		
Valeurs observées		Y=1	Y=0	Total
	Y=1	n11	n10	n11+n10
	Y=0	n01	n00	n01+n00
	Total	n11+n01	n10+n00	n

B. Gelein  
M. Depecker



1 - Matrice de confusion

Principe : confronter la vraie valeur avec la prédiction

		Valeurs prédites		
Valeurs observées		Y=1	Y=0	Total
	Y=1	n11	n10	n11+n10
	Y=0	n01	n00	n01+n00
	Total	n11+n01	n10+n00	n

B. Gelein  
M. Depecker



## 1 - Matrice de confusion

		Valeurs prédites		
		Y=1	Y=0	Total
Valeurs observées	Y=1	n11	n10	n11+n10
	Y=0	n01	n00	n01+n00
	Total	n11+n01	n10+n00	n

### Grandeurs d'intérêt

- Vrais positifs **VP = n11** ; Vrais négatifs **VN = n00**
- Faux positifs **FP = n01** ; Faux négatifs **FN = n10**

### Indicateurs

- Taux de bien classés  $\frac{n11 + n00}{n}$ , estime  $P(\hat{Y}=Y)$
- Taux d'erreur  $\frac{n01 + n10}{n}$ , estime  $P(\hat{Y} \neq Y)$

B. Gelein  
M. Depecker



7

## 1 - Matrice de confusion

### Indicateurs (suite)

		Valeurs prédites		
		Y=1	Y=0	Total
Valeurs observées	Y=1	n11	n10	n11+n10
	Y=0	n01	n00	n01+n00
	Total	n11+n01	n10+n00	n

- Taux de VP  $\frac{n11}{n11 + n10}$ , estime la **sensibilité**  $P(\hat{Y}=1 / Y=1)$
- Taux de FP  $\frac{n01}{n01 + n00}$ , estime  $P(\hat{Y}=1 / Y=0)$
- 1-Taux de FP  $\frac{n00}{n01 + n00}$ , estime la **spécificité**  $P(\hat{Y}=0 / Y=0)$

B. Gelein  
M. Depecker



8

## 1 - Matrice de confusion

Pour vérifier que le % d'individus correctement classés est significativement meilleur que par un classement aléatoire, on calcule le **Q-Press** :

$$Q_{press} = \frac{(n - (c \times k))^2}{n \times (k - 1)}$$

### Notations

- $n$  = taille échantillon
- $k$  = nombre de groupes  $\Rightarrow$  ici  $k=2$
- $c$  = nombre d'individus bien classés  $\Rightarrow c=n_{11}+n_{00}$
- Sous  $H_0$  (classe comme le hasard) ,  
Q-Press suit un  $\chi^2$  à 1 degré de liberté

B. Gelein  
M. Depecker



9

## 1 - Matrice de confusion

### Sensibilité et spécificité : une autre interprétation

- Notion de **score**
  - **Discrimination** de deux groupes  $G_1$  (les positifs,  $Y=1$ ) par rapport à  $G_2$  (les négatifs,  $Y=0$ ) à partir d'un **score**
  - **Règle de décision** : si  $\text{score} \geq \text{seuil}$  alors  $G_1$ , sinon  $G_2$
- En fonction du seuil  $z$  de séparation du score :
  - **Sensibilité** :  $\text{Sensi}(z) = P(\text{score} \geq z / G_1)$ 
    - probabilité de bien détecter un positif
  - **Spécificité** :  $\text{Spéci}(z) = P(\text{score} < z / G_2)$ 
    - probabilité de bien détecter un négatif

B. Gelein  
M. Depecker



10

## 1 - Matrice de confusion

### Lien entre *scoring* et classification binaire

- Un classifieur binaire peut s'écrire sous la forme :

$$C(x) = 2 \cdot \mathbf{I} \left\{ P(Y = +1 | X = x) \geq \frac{1}{2} \right\} - 1$$

où  $\mathbf{I}\{\cdot\}$  est la fonction indicatrice

- Ou plus généralement :

$$C_z(x) = 2 \cdot \mathbf{I} \{ s(x) \geq z \} - 1$$

où  $z$  est un seuil et  $s$  une fonction de score

B. Gelein  
M. Depecker



11

## 1 - Matrice de confusion

### Choix d'un classifieur : identification du seuil $z$

- Pour un modèle de score, on peut chercher la valeur de  $z$  qui maximise la sensibilité **ET** maximise la spécificité (minimise les faux positifs)

**Un bon classifieur permet de capturer le plus possible de vrais positifs avec le moins possible de faux positifs**

B. Gelein  
M. Depecker



12

## 2 – Courbe ROC

### Contexte de la classification binaire

- **ROC** : « Receiver Operating Characteristic »
- Plan ROC
  - en ordonnée : estimation de la **sensibilité** (TVP)
  - en abscisse : estimation de **1 - spécificité** (TFP)
- Un **classifieur** est caractérisé par un **point unique** dans l'espace ROC
- **Le plan ROC permet de comparer des classifieurs (et/ou des fonctions de score)**

B. Gelein  
M. Depecker




13

## 2 – Courbe ROC

### Exemple :

- A est meilleur que C  
(même TFP mais TVP plus élevé)
- A est meilleur que B  
(même TVP mais TFP plus faible)
- C est meilleur que E  
(même TVP mais TFP plus faible)
- B semble meilleur que E  
(presque même TFP mais TVP plus élevé)
- **E est globalement plus mauvais**
- **A est globalement meilleur**



B. Gelein  
M. Depecker




14

## 2 – Courbe ROC

### Point de vue du scoring

- Un classifieur s'écrit
 
$$C_z(x) = 2 \cdot \mathbf{I}\{s(x) \geq z\} - 1$$
- En faisant varier le seuil  $z$ , on obtient des couples  $(TFP_z, TVP_z)$
- Chaque point caractérise un classifieur qui correspond à la fonction de score  $s$  avec un seuil spécifié  $z$



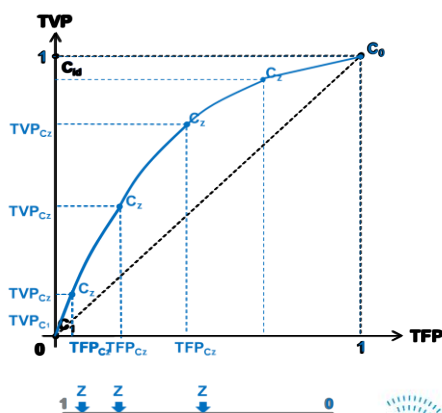
B. Gelein  
M. Depecker

15

## 2 – Courbe ROC

### Point de vue du scoring

- Un classifieur s'écrit
 
$$C_z(x) = 2 \cdot \mathbf{I}\{s(x) \geq z\} - 1$$
- En faisant varier le seuil  $z$ , on obtient des couples  $(TFP_z, TVP_z)$
- Chaque point caractérise un classifieur qui correspond à la fonction de score  $s$  avec un seuil spécifié  $z$
- ➔ En faisant varier le seuil  $z$ , on définit la courbe ROC



*Chaque point de la courbe ROC caractérise un classifieur qui correspond à la fonction de score  $s$  avec un seuil spécifié  $z$*

B. Gelein  
M. Depecker


16



Individu	Score	Y observé	TFP	TVP
			0	0.000
1	1	1	0.000	0.167
2	0.95	1	0.000	0.333
3	0.9	1	0.000	0.500
4	0.85	0	0.071	0.500
5	0.8	1	0.071	0.667
6	0.75	0	0.143	0.667
7	0.7	0	0.214	0.667
8	0.65	1	0.214	0.833
9	0.6	0	0.286	0.833
10	0.55	0	0.357	0.833
11	0.5	0	0.429	0.833
12	0.45	1	0.429	1.000
13	0.4	0	0.500	1.000
14	0.35	0	0.571	1.000
15	0.3	0	0.643	1.000
16	0.25	0	0.714	1.000
17	0.2	0	0.786	1.000
18	0.15	0	0.857	1.000
19	0.1	0	0.929	1.000
20	0.05	0	1.000	1.000

## Exemple

Courbe ROC



« meilleurs »



Source : R. Rakotomalala

B. Gelein  
M. Depecker

Individu	Score	Y observé	TFP	TVP
			0	0.000
1	1	1	0.000	0.167
2	0.95	1	0.000	0.333
3	0.9	1	0.000	0.500
4	0.85	0	0.071	0.500
5	0.8	1	0.071	0.667
6	0.75	0	0.143	0.667
7	0.7	0	0.214	0.667
8	0.65	1	0.214	0.833
9	0.6	0	0.286	0.833
10	0.55	0	0.357	0.833
11	0.5	0	0.429	0.833
12	0.45	1	0.429	1.000
13	0.4	0	0.500	1.000
14	0.35	0	0.571	1.000
15	0.3	0	0.643	1.000
16	0.25	0	0.714	1.000
17	0.2	0	0.786	1.000
18	0.15	0	0.857	1.000
19	0.1	0	0.929	1.000
20	0.05	0	1.000	1.000

Au seuil  $z = 1$ 

Observé	Prédit		Total
	Y=1	Y=0	
Y=1	1	5	6
Y=0	0	14	14
Total	1	19	20

$$TVP = 1/6 = 0,167 \quad TFP = 0/14 = 0$$

Au seuil  $z = 0,95$ 

Observé	Prédit		Total
	Y=1	Y=0	
Y=1	2	4	6
Y=0	0	14	14
Total	2	18	20

$$TVP = 2/6 = 0,333 \quad TFP = 0/14 = 0$$



Source : R. Rakotomalala

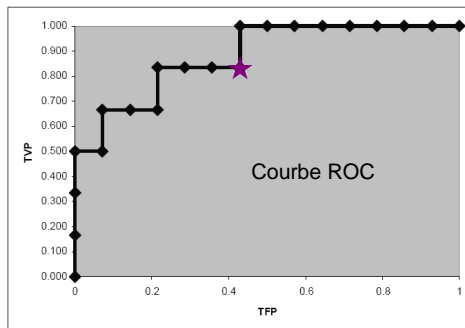
B. Gelein  
M. Depecker

Individu	Score	Y observé	TFP	TVP
			0	0.000
1	1	1	0.000	0.167
2	0.95	1	0.000	0.333
3	0.9	1	0.000	0.500
4	0.85	0	0.071	0.500
5	0.8	1	0.071	0.667
6	0.75	0	0.143	0.667
7	0.7	0	0.214	0.667
8	0.65	1	0.214	0.833
9	0.6	0	0.286	0.833
10	0.55	0	0.357	0.833
11	0.5	0	0.429	0.833
12	0.45	1	0.429	1.000
13	0.4	0	0.500	1.000
14	0.35	0	0.571	1.000
15	0.3	0	0.643	1.000
16	0.25	0	0.714	1.000
17	0.2	0	0.786	1.000
18	0.15	0	0.857	1.000
19	0.1	0	0.929	1.000
20	0.05	0	1.000	1.000

Au seuil  $z = 0,5$

Observé	Prédit		Total
	Y=1	Y=0	
Y=1	5	1	6
Y=0	6	8	14
Total	11	9	20

TVP=5/6=0,833    TFP=6/14=0,429



Source : R. Rakotomalala


B. Gelein  
M. Depecker

### Package R : TeachingDemos


```
roc.demo(x = rnorm(25, 10, 1),
y = rnorm(25, 11, 1.5))
```

**Ici paramètre x de roc.demo :**  
distribution du score pour  
la modalité 0 de Y

**Ici paramètre y de roc.demo :**  
distribution du score pour  
la modalité 1 de Y



- Densité des positifs : *bleu*
- Densité des négatifs : *rouge*



B. Gelein  
M. Depecker

**Package R : TeachingDemos**


```
roc.demo(x = rnorm(25, 10, 1),
y = rnorm(25, 11, 1.5))
```

**Ici paramètre x de roc.demo :**

distribution du score pour  
la modalité 0 de Y


**Ici paramètre y de roc.demo :**

distribution du score pour  
la modalité 1 de Y





## • Echantillonnage

- Positifs
- Négatifs


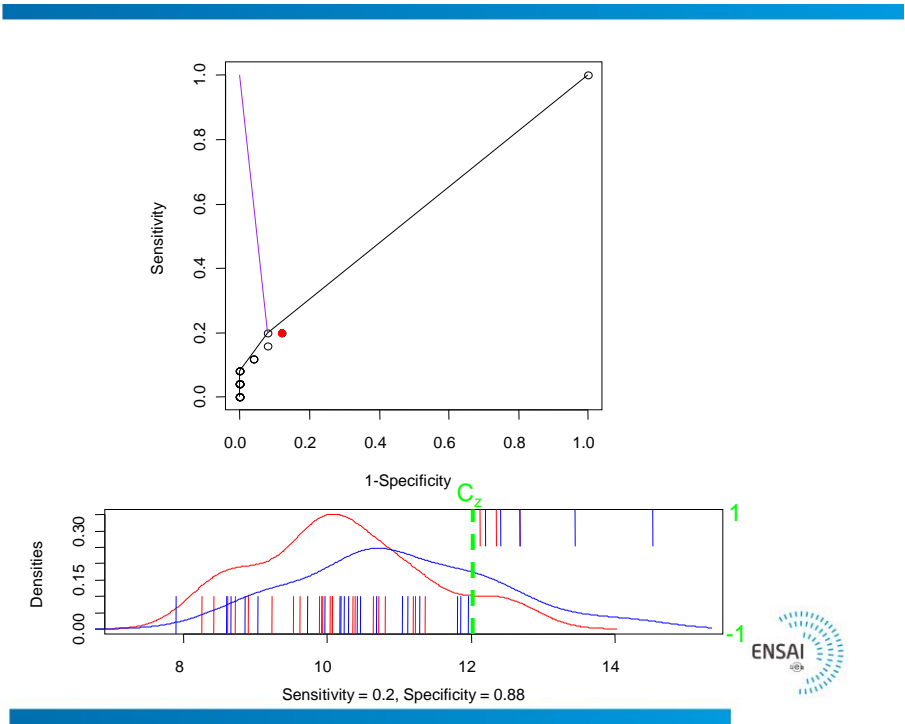


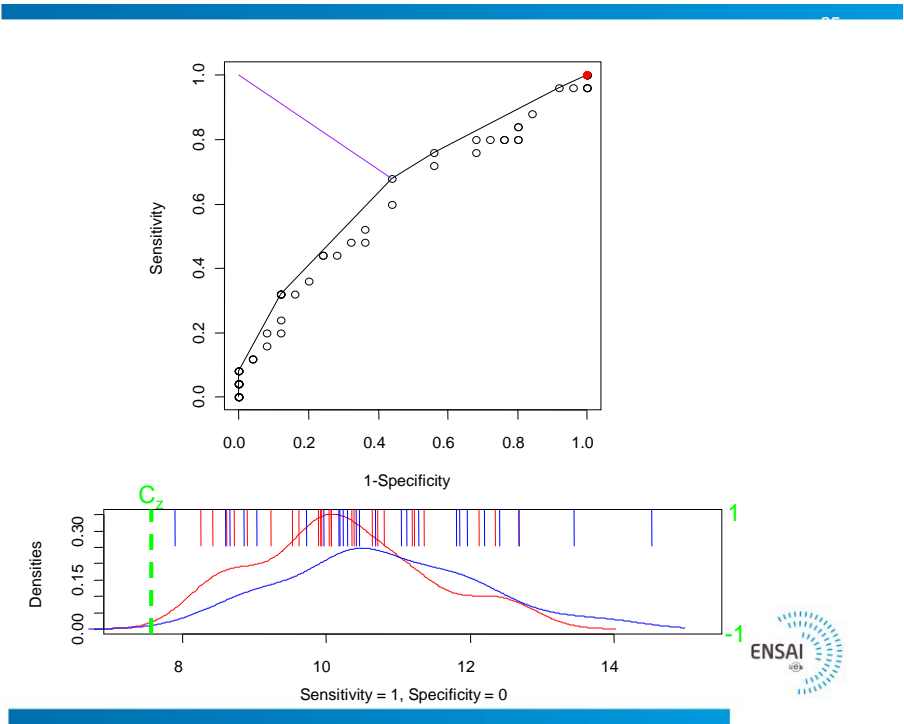
B. Gelein  
M. Depecker



B. Gelein  
M. Depecker








B. Gelein  
M. Depecker

## 2 – Courbe ROC

### Propriétés de la ROC : une courbe paramétrique

- Collection de classifieurs binaires :  
 $\{C_z(x) = 2 \cdot \mathbb{I}\{s(x) \geq z\} - 1, z \in \mathbb{R}\}$
- Taux de faux positifs (TFP) :  
 $\text{TFP}_s(z) = \mathbb{P}\{s(X) \geq z \mid Y = -1\}$
- Taux de vrais positifs (TVP) :  
 $\text{TVP}_s(z) = \mathbb{P}\{s(X) \geq z \mid Y = +1\}$


ROC :  $z \mapsto (\text{TFP}_s(z), \text{TVP}_s(z))$



B. Gelein  
M. Depecker

## 2 – Courbe ROC

### Propriétés de la ROC



27

## 2 – Courbe ROC


### Propriétés de la ROC

- Elles est **invariante** pour toute transformation monotone croissante du score
- **C'est un outil de comparaison de modèles (scores et classifieurs)**

28

## 2 – Courbe ROC

### Propriétés de la ROC



- La courbe ROC induit un **ordre partiel** sur l'ensemble des fonctions de score  $\mathcal{S}$
- $s_1$  est plus performante que  $s_2$  **ssi**  
 $\forall \alpha \in ]0,1[, \text{ROC}(s_1, \alpha) \geq \text{ROC}(s_2, \alpha)$


- La courbe ROC optimale correspond à la probabilité  $\eta$   
 $\forall s \in \mathcal{S}, \forall \alpha \in ]0,1[,$   
 $\text{ROC}^*(\alpha) = \text{ROC}(\eta, \alpha) \geq \text{ROC}(s, \alpha)$   
**(argument de Neymann-Pearson)**

où  $\eta(x) = P(Y = +1 | X = x)$

B. Gelein  
M. Depecker

29

## 2 – Courbe ROC



Modèle(s) M1 —

Modèle(s) M2 - - -

La courbe de M1 est toujours « au-dessus » de celle de M2 :

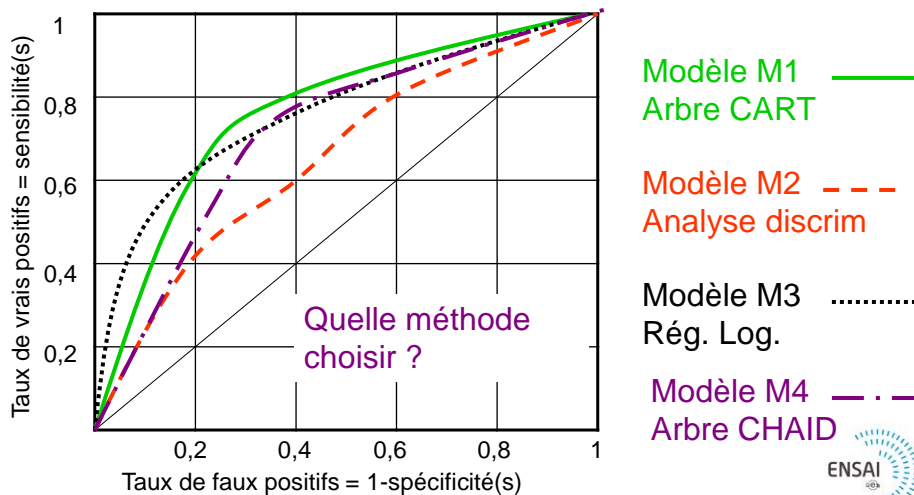
les classifieurs de M1 sont meilleurs en prédiction quel que soit le seuil  $z$



B. Gelein  
M. Depecker

30

## 2 – Courbe ROC



B. Gelein  
M. Depecker



31

## 2 – Courbe ROC

**Enveloppe convexe – ou comment éliminer d'office les modèles les moins intéressants ?**

- L'**enveloppe convexe** permet d'effectuer une première sélection dans un **ensemble de modèles** donné
- Elle est formée par **les courbes** ou **parties de courbes**, telles qu'il n'existe pas d'autre courbe « au-dessus » d'elles
- Les courbes situées **sur cette enveloppe** correspondent aux **modèles les plus performants** pour une matrice de coût donnée


B. Gelein  
M. Depecker



32



## 2 – Courbe ROC



B. Gelein  
M. Depecker



## 2 – Courbe ROC

### Enveloppe convexe – ou comment éliminer d'office les modèles les moins intéressants ?

- Sont **éliminés d'office** les modèles ne participant jamais à cette enveloppe
- Dans l'exemple, l'enveloppe convexe est formée par les courbes de M1 (arbre de classement CART) et M3 (régression logistique).
  - M2 est dominé par tous les modèles, il est donc éliminé.
  - M4 peut être meilleur que M3 dans certains cas, mais pour ces cas là, il s'avère moins bon que M2. M4 est donc éliminé.

B. Gelein  
M. Depecker




34

## 2 – Courbe ROC

### Autre usage de la courbe ROC

- On peut aussi tracer les courbes ROC correspondant à une entrée progressive de variables dans un modèle



B. Gelein  
M. Depecker

Source : Tufféry

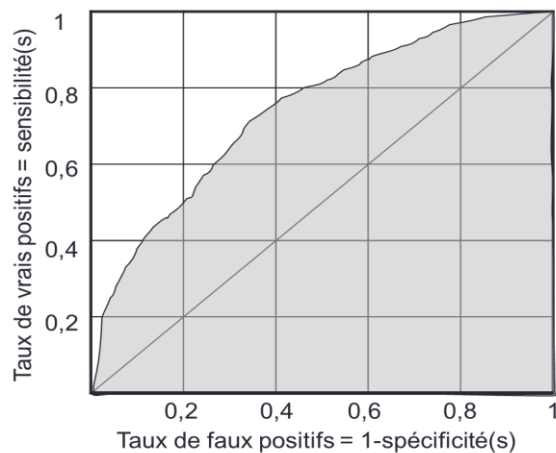


35

## 3 – Aire sous la courbe ROC

### Aire AUC sous la courbe ROC

$$AUC(s) = \int_{\alpha=0}^1 ROC(s, \alpha) d\alpha$$



B. Gelein  
M. Depecker

36

### 3 – Aire sous la courbe ROC

#### Aire AUC sous la courbe ROC

- La **capacité prédictive** d'un modèle est d'autant meilleure que l'aire **AUC est proche de 1**
- Si l'**AUC = 0,5** alors le modèle n'est pas meilleur qu'une **prédiction aléatoire** (ROC = diagonale)
- Estimation de la probabilité que pour tout couple (A,B)  
 $\text{score}(\text{individu A}) > \text{score}(\text{individu B})$ ,  
 avec A tiré au hasard dans le groupe G1 (à prédire, par ex « positif ») et B dans le groupe G2

Interprétation : *taux de paires concordantes*

B. Gelein  
M. Depecker



37

### 3 – Aire sous la courbe ROC

#### AUC - trois méthodes d'estimation

1. Méthode des trapèzes
2. Interprétation probabiliste: taux de paires concordantes

$$\begin{aligned}
 \forall (X, X') \in \mathcal{X}^2, s \in \mathcal{S} \text{ et pour } p = \mathbb{P}\{Y = 1\}, \\
 \text{AUC}(s) &= \mathbb{P}\{s(X) > s(X') \mid (Y, Y') = (+1, -1)\} \\
 &+ \frac{1}{2} \cdot \mathbb{P}\{s(X) = s(X') \mid (Y, Y') = (+1, -1)\} . \\
 &= 1 - \frac{1}{2p(1-p)} \cdot \mathbb{P}\{(s(X) - s(X'))(Y - Y') < 0\}
 \end{aligned}$$

B. Gelein  
M. Depecker



38

### 3 – Aire sous la courbe ROC

#### Estimation du taux de paire concordantes :

- Soit  $n_1$  (resp.  $n_2$ ) le nombre d'observations dans  $G_1$  (resp.  $G_2$ )
- Soient les  $n_1 \times n_2$  paires formées d'un individu  $x_1$  du groupe  $G_1$  et d'un individu  $x_2$  du groupe  $G_2$
- Parmi ces  $n_1 \times n_2$  paires on a :
  - concordance si  $\text{score}(x_1) > \text{score}(x_2)$
  - discordance si  $\text{score}(x_1) < \text{score}(x_2)$
  - $n_c$  = nombre de paires concordantes
  - $n_d$  = nombre de paires discordantes
  - $n_e = n_1 \times n_2 - n_c - n_d$  = nombre d'ex æquo

$$AUC \approx \frac{n_c + \frac{1}{2}(n_1 \times n_2 - n_c - n_d)}{n_1 \times n_2}$$

B. Gelein  
M. Depecker



39

### 3 – Aire sous la courbe ROC

#### 3. Méthode de Mann-Whitney

- L'AUC peut s'exprimer en fonction de la statistique de test de Mann-Whitney  $U$  :  $AUC = \frac{U}{n_1 \times n_2}$
- $U$  est une statistique de test non-paramétrique permettant d'évaluer l'homogénéité entre deux populations où  $R_1$  (resp.  $R_2$ ) est la somme des rangs des individus de  $G_1$  (resp.  $G_2$ ), et

$$U = R_1 - \frac{n_1(n_1+1)}{2} = R_2 - \frac{n_2(n_2+1)}{2}$$

$$R_1 + R_2 = \frac{N(N+1)}{2}, \quad \text{avec } N = n_1 + n_2$$

B. Gelein  
M. Depecker



40

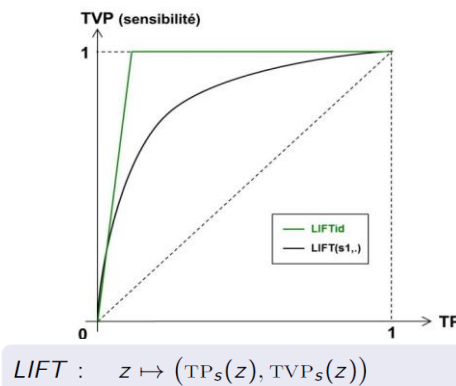
## 4 – Courbe LIFT

### Courbe LIFT ou courbe de gain

- Objectif : La démarche du ciblage - marketing

*Exemple* : publipostage pour la promotion d'un produit

- Taux de répondants vs taux d'individus ciblés
  - Ordonnée :  
estimation de la sensibilité  
 $\text{Proba}(\text{score} \geq s / G1)$  (TVP)
  - Abscisse :  
estimation du taux de positifs  
 $\text{Proba}(\text{score} \geq s)$  (TP)



B. Gelein  
M. Depecker



41

## 4 – Courbe LIFT

### Courbe LIFT ou courbe de gain

- Cette courbe représente la proportion de vrais positifs en fonction des individus sélectionnés, lorsque l'on fait varier le seuil  $z$  du score
- **Sa forme dépend du taux de positifs *a priori***
- Même ordonnée que la courbe ROC, mais une abscisse généralement plus grande
- La courbe de lift est généralement sous la courbe ROC
- **ROC et LIFT représentent une information similaire**
  - La diagonale du plan représente une prédiction aléatoire
  - La courbe idéale LIFT est la plus proche du coin supérieur gauche

B. Gelein  
M. Depecker



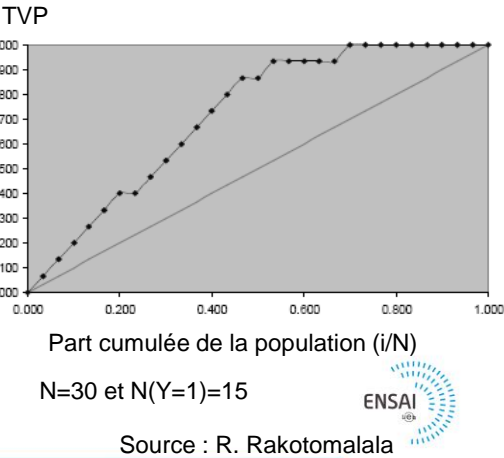
42

Individu	Y observé	Score	Part cum. de Population	TVP
			0	0.000
1	1	1.000	0.033	0.067
2	1	1.000	0.067	0.133
3	1	0.999	0.100	0.200
4	1	0.999	0.133	0.267
5	1	0.998	0.167	0.333
6	1	0.992	0.200	0.400
...	...	...	...	...
19	0	0.294	0.633	0.933
20	0	0.109	0.667	0.933
21	1	0.073	0.700	1.000
22	0	0.035	0.733	1.000
23	0	0.024	0.767	1.000
24	0	0.016	0.800	1.000
25	0	0.015	0.833	1.000
26	0	0.009	0.867	1.000
27	0	0.004	0.900	1.000
28	0	0.003	0.933	1.000
29	0	0.002	0.967	1.000
30	0	0.000	1.000	1.000

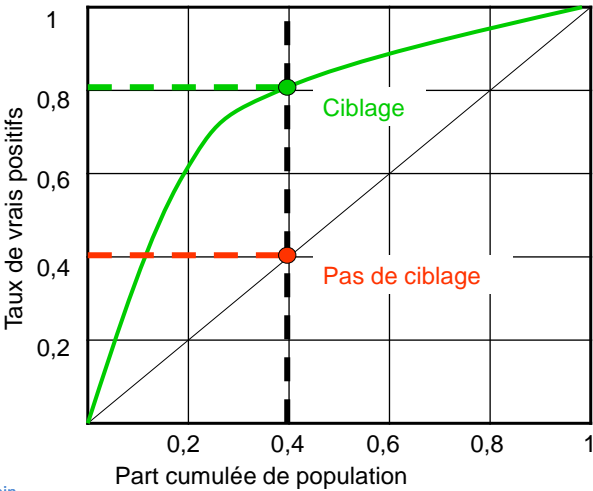
B. Gelein  
M. Depecker

### Courbe LIFT

Les données sont triées selon les scores décroissants



### 4 – Courbe LIFT




B. Gelein  
M. Depecker

Optique  
« budget fixé »



## 4 – Courbe LIFT



Objectif =  
part de  $Y=1$

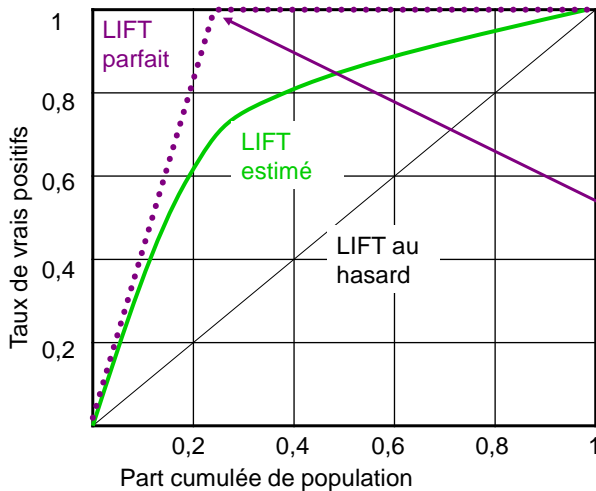
Exemple : « part  
de marché »

B. Gelein  
M. Depecker



45

## 4 – Courbe LIFT



Ciblage parfait :  
Les premiers individus  
de la base ont tous  
 $Y=1$

B. Gelein  
M. Depecker



46

## 4 – Courbe LIFT

### Lien entre courbe de LIFT et courbe ROC

- Si la courbe ROC(s) domine dans le plan (TVP,TFP) alors la courbe LIFT(s) domine dans le plan (TVP,TP) et la fonction de score s est la plus performante

B. Gelein  
M. Depecker



47

## 5 – Aire sous la courbe LIFT

### Lien entre les aires sous les courbes LIFT et ROC

- On note souvent AUC, parfois AUL l'aire sous la courbe LIFT
- L'AUL s'exprime simplement à partir de l'AUC

$$AUL = \frac{p}{2} + (1 - p) AUC$$

où  $p = \text{Proba}(G1) = \text{probabilité a priori de l'événement } Y=1 \text{ dans la population}$

B. Gelein  
M. Depecker



48



## 5 – Aire sous la courbe LIFT

### Lien entre courbe de LIFT et courbe ROC

- Cas particuliers :
  - $AUC = 1 \Leftrightarrow AUL = p/2 + (1 - p) = 1 - p/2$
  - $AUC = 0,5 \Leftrightarrow AUL = p/2 + 1/2 - p/2 = 0,5$
  - Si  $p$  est petite  $\Leftrightarrow AUC$  et  $AUL$  sont proches
  - $AUC(M1) > AUC(M2) \Leftrightarrow AUL(M1) > AUL(M2)$

B. Gelein  
M. Depecker



49

## 6 - Conclusion

### 6.1 – Avantages et Limites

#### Courbes ROC et LIFT

- Des critères fonctionnels
  - Faciles à visualiser *a posteriori*
  - Difficiles à optimiser directement

**Alternative : les aires sous les courbes et critères dérivés**
- La courbe ROC ne permet pas de visualiser le rapport entre les deux classes
 

**Difficulté : elle peut induire en erreur dans le cas d'échantillons fortement déséquilibrés**
- La forme de la courbe LIFT dépend de l'équilibre des classes dans l'échantillon
 

**Difficulté : elle doit être lue *relativement* à la LIFT idéale**

B. Gelein  
M. Depecker



50

## Conclusion

### 6.1 – Avantages et Limites

#### AUC et AUL

- Des critères réels
  - Simples à calculer et à optimiser
  - L'AUC a une interprétation probabiliste intuitive
- Des critères globaux
  - deux fonctions scores optimales auront **même AUC** mais des **courbes ROC** possiblement **différentes...**
  - ...l'une pouvant être **meilleure que l'autre sur une portion** des individus!
  - Ne permettent pas de se focaliser sur les **meilleures observations**

B. Gelein  
M. Depecker

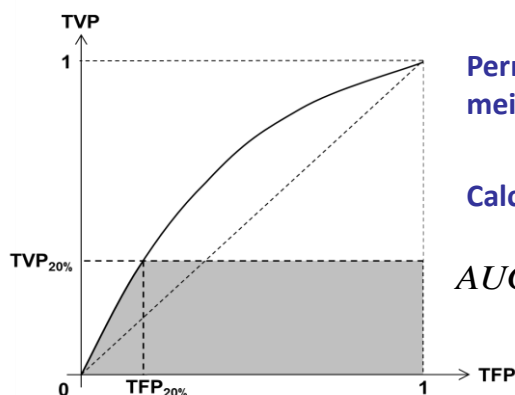


51

## Conclusion

### 6.2 – Alternatives

#### Exemple: l'AUC partielle



Permet de se focaliser sur les x%  
meilleures observations

Calcul simple :

$$AUC_{\text{tronquée } x\%} + (1 - TFP_{x\%}) \times TVP_{x\%}$$

B. Gelein  
M. Depecker

S. Cléménçon & N. Vayatis, *Ranking the best instances*, Journal of Machine Learning Research, vol 8, pp 2671-2699, 2007



52